

Segunda parte del curso de visión por computador de las series que SpainAI ha impartido durante el confinamiento de Abril 2020. La [primera parte](#) vimos sobre conceptos teóricos detrás del deeplearning para uso en imágenes y desde la experiencia en gestión de proyectos de deeplearning os dimos recomendaciones que se podrían resumir en los siguiente puntos:

- Categorizar vuestro problema tratando de simplificarlo al máximo (tipo y clases)
- Maximizar el tiempo y presupuesto del proyecto en vuestro Dataset
- Buscar GPUs (Colab, Preemptibility en gcloud o Spot instances en AWS)
- Elegid vuestra arquitectura según el uso final (edge,cloud)
- Preprocesar imágenes y crear ejemplos artificiales con data augmentation
- Transfer learning y elegir un modelo bien entrenado

[Repositorio con todos los notebooks](#)

[Dataset](#) 5,6Gigas

Sobre COVID-NET: dataset + CNN

Es un dataset creado en Vision and Image Processing Research Group, University of Waterloo, Canada y que se comparte a [través de github](#) y publicaron un [paper](#) Especifican “They are currently at a research stage and not yet intended as production-ready models (not meant for direct clinicial diagnosis)” pero explican que puede ayudar a los médicos a escoger quién es susceptible de ser priorizado para test PCR. El dataset se llama “open source COVIDx dataset” y la CNN que crearon se llama “COVID-RiskNet”. Podéis escuchar [un webinar de 50mns](#) por parte de los autores

¿ Porqué crean una nueva arquitectura ?

Buscan la optimización y que pueda funcionar en edge devices además de Cloud. En deeplearning la performance de un algoritmo se puede medir en Flops (que es una medida que se usa en GPUs).




Figure 2. **COVID-Net Architecture.** High architectural diversity and selective long-range connectivity can be observed as it is tailored for COVID-19 case detection from chest radiography images. The heavy use of a projection-expansion-projection design pattern in the COVID-Net architecture can also be observed, which strikes a strong balance between computational efficiency and representational capacity.

Normalmente, en los papers se proporcionan los detalles del entreno. *The following hyperparameters were used for training: learning rate=2e-5, number of epochs=10, batch size=8, factor=0.7, patience=5. Furthermore, data augmentation was leveraged with the following augmentation types: translation, rotation, horizontal flip, and intensity shift.*

Dataset

16,756 radiografías de torax de 13,645 pacientes, creado con una combinación de dos datasets de acceso abierto (Cohen et al. COVID-19 image data collection.) COVIDx dataset contiene **solamente** 76 radiografías de 53 COVID-19 patient cases. More specifically, there are a total of 8066 patient cases who have no pneumonia (i.e., normal) and 5526 patient cases who have non-COVID19 pneumonia.

COVID 2020 [Radiological Society of North America](#).
[Kaggle](#) RSNA pneumonia detection challenge.




(A)



(B)

Figure 1. Example chest radiography images of: (A) non-COVID19 infection, and (B) COVID-19 viral infection in the COVIDx dataset.



Críticas

"Hey we can get free publicity for our business by publishing a paper that says 'AI', 'Deep learning', and 'COVID' all in the abstract"

Sobre el dataset

1. Diferentes fuentes de datos
2. No detallan el grado de la enfermedad (leve, severo) ni tipos de pacientes
3. Desbalanceado y demasiados pocos ejemplos de Covid-19

Sobre el transfer learning

Los datos usados rayos-X y los que se usaron para entrenar el modelo (animales y comida) no tienen nada que ver. En general no parece haber consenso sobre si modelos preentrenados benefician frente a inicialización random de los pesos de las neuronas.

[Aquí](#) tenéis un interesante estudio recopilatorio sobre diferentes técnicas para resolver estos problemas y un [paper](#) de Google Brain solamente sobre este asunto